



大学生创新创业训练计划项目

研究总结报告

所在院系：人工智能与自动化学院

指导老师：肖阳

项目成员：甘锦芳，张新涛，梁一凡，严永昕

结题时间：2024 年 4 月 12 日

目录

- 摘要 1
- 1. 背景介绍 2
 - 1.1 研究背景 2
 - 1.2 研究意义与应用场景 3
- 2.相关工作 4
 - 2.1 眨眼检测 4
 - 2.2 重复动作计数 6
 - 2.3 弱监督行为检测 8
 - 2.4 视线估计 9
 - 2.5 多人眨眼检测数据集 10
- 3.眨眼计数算法分析 11
 - 3.1 多人条件下眨眼计数挑战分析 11
 - 3.2 多人条件下眨眼计数算法分析 12
- 4.效果展示 13
 - 4.1 多人条件下眨眼计数眨眼指标对比 13
 - 4.2 视线估计在 MPEblink 上的可视化 14
- 5.主要工作和创新点 15
- 参考文献 16

摘要

随着科技的发展和技术的进步，各行各业都在新技术的发展下有了很多变化。体育竞技类项目就是其中之一。传统的体育运动可以追溯到古代文明时期，人们生活中的各种活动和竞技中逐渐形成了各种形式的体育运动。在古希腊时期，奥林匹克运动会就已经成为了一项盛大的赛事，吸引了来自各地的运动员参加。

随着计算机技术的发展，人们的娱乐方式逐步转移到电子设备上，电子竞技在全球范围内的规模和影响力逐渐增大。电子竞技已成为了一种全球性的文化现象，拥有着数亿的粉丝和数十亿美元的市场规模。

在全球范围内举办的电子竞技赛事，如《英雄联盟》世界总决赛、DOTA2 国际邀请赛、Overwatch 联赛等，已经成为了全球电子竞技爱好者和游戏玩家瞩目的焦点。这些电子竞技游戏无一不需要参赛者集中注意力感知游戏环境，来作出及时准确的决策。

除了这些 moba, FPS 等单人高强度对抗类型游戏，新兴的多人体感游戏如任天堂的健身环，马里奥派对等，在满足对抗竞技乐趣同时还能有锻炼身体的效果。和传统电子竞技游戏一样，这些游戏对玩家的注意力也有相当要求，在这种情况下使用传统的视线估计和眨眼检测手段来对玩家注意力进行检测容易受到追踪精度，姿态变化的影响。

为了解决多人人体感游戏下注意力估计问题，我们提出了一种多人眨眼计数算法，它能在仅有眨眼次数监督的条件下，实现精确的眨眼计数，并有媲美全监督的眨眼检测能力。同时我们也复现了 MCGage，一种多人并行视线估计算法。

1.背景介绍

1.1 研究背景

随着计算机技术的发展，人们的娱乐方式逐步转移到电子设备上，电子竞技在全球范围内的规模和影响力逐渐增大，已经成为了一种全球性的文化现象，拥有着数亿的粉丝和数十亿美元的市场规模，其中著名的有英雄联盟职业联赛、DOTA2 职业联赛、CSGO Major 等。这些职业电竞运动员需要在注意力高度集中的状态下快速感知游戏环境并及时做出准确决策。

在电子游戏中，新兴的多人体感游戏近年来发展势头强劲。根据市场研究报告，2021 年全球体感游戏市场规模为 48908 万美元，预计到 2031 年市场规模将达到 398878 万美元，预测期内复合年增长率为 21.19%。在中国，体感游戏市场也表现出强劲的增长势头。2022 年中国体感游戏市场规模达到了数亿元人民币。与 moba, FPS 等单人高强度对抗类型游戏相比，在多人体感游戏中，如任天堂的健身环，马里奥派对等，玩家不仅享受到竞技的乐趣，还能在游戏中锻炼身体。

无论是在紧张的电子竞技中还是在日常的游戏娱乐中，准确监测和评估玩家的注意力水平都非常重要，尤其是在多人体感游戏中，玩家的互动性和沉浸感要求更高，对注意力的集中程度有着更为严格的要求，任何分心都可能导致游戏体验的下降或竞技表现的不佳。准确捕捉和分析玩家注意力，不仅可以帮助游戏开发者更好地理解玩家行为，优化游戏设计，提升玩家体验，还可以在电子竞技训练中作为运动员状态监测和训练效果评估的重要工具。

然而，传统的注意力监测方法往往受限于追踪精度和姿态变化的影响，在多人场景下的应用效果并不理想。因此，研究一种适用于多人场景，能够准确监测注意力的方法，对于提高竞技水平和改善游戏体验具有重要意义。

1.2 研究意义与应用场景

计算机视觉的电子竞技辅助系统的研究具有重要的意义和广阔的应用前景。一方面，这些系统的开发可以帮助选手提高游戏水平，从而提高电子竞技比赛的竞争水平和观赏性。另一方面，研究这些系统也可以促进计算机视觉技术的发展和應用。通过研究这些系统，我们可以进一步深入了解计算机视觉在实际应用中的挑战和机遇，并探索新的技术和算法来提高这些系统的性能和可靠性。

本项目不仅能够为电子竞技和多人体感游戏领域提供更为准确的注意力监测手段，还能够其他领域发挥重要作用。我们的方法有如下应用场景：

电子竞技辅助：对于电子竞技运动员，本项目可以帮助选手更好地掌握竞技技巧，把握赛场形势。此外还可以帮助选手制定合理的训练计划，避免过度疲劳。

游戏交互辅助：对于行动不便的玩家，本项目可以让他们能够通过视线移动和眨眼来游玩电子游戏。例如，在射击游戏中，玩家可以通过移动视线来瞄准和射击目标，通过眨眼触发特定的游戏动作。

游戏设计辅助：对于电子游戏开发者，本项目可以帮助他们利用注意力监测数据来分析玩家的行为模式，优化游戏设计，提升玩家的游戏体验。

教学辅助：对于教育工作者，本项目可以帮助他们监测学生的注意力情况，以便改进教学内容和教学方式，提高教学质量。

商业活动辅助：对于企业，本项目可以帮助企业评估商业广告海报的宣传效果并进行改进，提高广告的传播力。

2.相关工作

2.1 眨眼检测

眨眼检测一直以来都是计算机视觉领域的热门问题，但是目前为止绝大多数的方法主要针对场景单一、光照均匀的受限条件下的单人眨眼检测。并且主要基于 ZJU^[1]、Eyeblink8^[2]、Talking face^[3]、Silesian5^[4]和 mEBAL^[5]等受限环境下的数据集。（见下图）




HUST-LEBW^[6]是一个非受限条件下的单人视频数据集，其针对上述受限条件的单人视频数据集的局限性进行了突破。该数据集包含有选自 20 个不同的商业片的 671 个眨眼片段，包括了姿态变化、人种变化、运动模糊等非受限条件，具有“在野外”的特征。（见下图）



HUST-LEBW 虽然率先引入了“非受限条件”突破了以往数据集的环境要求，但是总体而言这些算法 pipeline 都是人脸检测追踪再特征提取回归，其在多人场景下的效率不高，而且易受追踪精度影响。

Instblink^[7]是首个在非受限条件下的多人一体化眨眼检测算法，一体化的模型结构能够使得其更少受到追踪精度干扰，并且具有更广的特征感受野，能够更好的感知姿态信息，能够在多人复杂非限制场景下获得更好的性能。同时减少了二次特征提取步骤，避免因场景人数增加导致推理时间线性增加。（整体框架如下）




整体流程为,对输入视频序列 $T \times C \times H \times W$,对每一帧用 resnet50 为 backbone 做特征提取，生成特征金字塔以适应不同尺度的眼部信息，而后使用可学习的 $N \times D$, query 复制 $B \times T$ 次，也就是每一帧都对应相同的 N 个 query，这 N 个 query 每个都先生成 ROI, 通过 ROIalign 获取的图像特征作为新 query, query

再通过两个任务头，分别对 face bbox 和 blink score 预测，再在空间和时间维度做 self-attention 来交互信息，以上流程重复迭代 M 次。推理时则取最后一次迭代的结果作为预测结果。

2.2 重复动作计数


重复动作计数是指对一个特定的周期动作进行计数，例如举重中的卧推次数、跳绳中的跳绳次数等。近年来，随着计算机视觉和深度学习等技术的发展，重复动作计数也成为了研究热点之一。相关的研究成果可以应用于多种场景，例如 体育竞技、医疗康复、虚拟健身等。

早期的行为计数方法如 Live repetition counting^[8] (见下图)



主要是一些基于简单的 cnn 提取特征，再通过分类，次数标签监督的办法。这里是将图像序列特征提取后，作分类获取结果。原因是作者认为这里取固定大小滑窗其实已经大致确定了重复次数范围，不如直接分类每种次数的概率而不是做回归。但是这种方法没有充分利用重复动作之间的相互关联，难以捕捉一些周期性较弱，或者相对稀疏的重复行为。


基于相似度矩阵的方法如 transRAC^[9] (见下图)



这种方法则不再是通过卷积建立重复行为之间的关联，而是通过对每一帧图像特征的相似度求自相关矩阵，通过对这个自相关矩阵卷积，回归获得最终计数结果。这种方法引入了周期运动的关键帧相似度高的先验知识，并且在不同时间 stride 下求相似度矩阵以适应不同尺度重复行为。并且引入了细粒度的标签标识了每一次运动的开始结束帧，而不是只给次数标签，更容易使模型学到关键信息。

除了基于相似度矩阵的方法，还有基于 transformer 建模帧间关系的方法。

如 poseRAC^[10] (见下图)




基于 transformer 建模方法相对于相似度矩阵，相比较相似度矩阵加卷积的方法能够建模更加复杂的关系，并且时间复杂度由 $O(n^2)$ 降到 $O(n^1)$ 。另外它给出了更加细粒度的标注，除了动作区间，还有每次动作差别最大的两帧，

比如上下蹲的最高点和最低点。另外它不直接使用图像特征，而是通过 pose 关节节点信息作为输入，极大去除了信息冗余。另外除了很常见的区间监督，它还对每次动作差别最大的两帧作三元组损失，拉开背景类和前景类的差别。

2.3 弱监督行为检测

弱监督行为检测能够不依赖确切的区间标签实现动作检测功能，能够极大降低标注代价，是一个热门计算机视觉任务。弱监督行为检测比较经典的方法是通过多分类来做区间预测。它能够不依赖细粒度的动作标签，来检测多种运动类别，例如 Weakly-supervised Temporal Action Localization by Uncertainty Modeling^[11] (见下图)




它借助了光流与 RGB 特征，并且分别预测每一帧对应各类别的概率，并沿着时间维度求和，再根据动作类别标签求交叉熵损失。另外对每一类别通过阈值获取每类标签的区间伪标签，然后对挑出来的背景类特征和前景特征做三元组损失，并且强制背景类帧得分服从给定分布，减少背景类干扰。

2.4 视线估计


最近几年的研究里，基于外观的视线估计方法在简单外设的情况下对受试者进行视线估计逐渐热门。早期基于外观的方法受限于环境和固定受试者。随着深度学习的发展，给基于外观的提供了一种解决问题的新思路，从而有了有关深度学习的基于外观的方法。

例如 FAZE^[12] 是由 Seonwook Park 等人在 2021 年提出的一种用于估计人眼注视方向的算法。它基于神经网络和元学习的思想，可以在很少的样本量下进行快速的个性化训练。FAZE 的主要思路是通过少量的训练样本来适应新用户的个性化特征，从而提高注视方向的准确性和稳定性。FAZE 的视线估计分为两个部分：元学习网络和个性化网络。元学习网络用于学习如何快速适应新用户的特征，它可以根据少量的样本来预测每个用户的眼部特征。个性化网络则用于根据用户的眼部特征来进行注视方向的估计。

FAZE 模型的框架：



除了传统的检测-估计范式，一体化的检测-视线估计能够减少二次特征提取带来的额外时间开销，还能共同优化检测，视线估计两个任务。如 End-to-end Video Gaze Estimation via Capturing Head-face-eye Spatial-temporal InteractionContext^[13] (见下图)，因为当前视线估计数据集都只是针对单人样本，这里并没有拓展到多人。



总体流程和 instblink 类似，不过是对单人。而且除了原有的人脸检测，还增加了人头和眼睛检测，这种 coarse to fine 结构能够提高追踪精度。

2.5 多人眨眼检测数据集

MPEBlink 是目前唯一针对非受限条件下的多人长视频数据集。包含 86 部不同的没有类别限制的电影中收集的 686 个不同长度（时长范围 7.1-85.9s）的未修剪视频片段。



不过其中大部分都是五人以下的样本，为了能够更好地测试我们模型在多人场景下的能力，我们额外收集了 200 个五人以上的样本，四千多个眨眼标注，丰富了数据集场景，进一步加大了眨眼检测难度，弥补了 MPEBlink 缺少密集多人样本的缺憾。

3. 眨眼计数算法分析

3.1 多人条件下眨眼计数挑战分析

眨眼计数与其他常见重复行为计数（如来回跑，上下蹲等）相比，具有细粒度，稀疏性，周期性弱的特点。眨眼持续时间只有 0.2-0.4 秒，意味着训练时选取的时间窗口的 stride 不能太大。同时人一分钟正常眨眼次数仅有 15 次，在注意力集中时甚至频率更低，为了获取足够丰度的计数标签，这就要求我们训练时间长度必须足够大。


一体化眨眼检测需要对高分辨率图像做特征提取来获取眼部信息，如果基于现有的多人眨眼计数算法 instblink 上修改，那么因为硬件限制，就难以满足长

序列训练要求。

3.2 多人条件下眨眼计数算法分析


为了解决上述问题，我们提出了一个两阶段的多人眨眼计数算法：

第一阶段训练，模型主要任务是追踪输入序列所有人脸，除此之外，为了强迫模型能够提取带有眼部的外观信息的特征，我们另外增加了追踪人眼部的任务。



第一部分阶段训练完成后，冻结模型参数，再在所有样本上推理一遍。推理过程中，依据追踪的眼部位置在原始图像特征做 ROIalign，获取的特征作为眨眼使用的特征，用作第二阶段训练。并且只有 IOU 大于 50%的样本会被考虑。

第二阶段训练，获取的眨眼特征经时序特征提取，在使用次数监督和稀疏性约束下生成 proposal，再通过先验知识进行 refine，通过滑窗获取最有可能的 k 个互不重叠的眨眼位置， k 是眨眼次数。并生成能够适应不同时间尺度的眨眼伪标签，也就是只给预测区间最中间正标签，最边缘给负标签，其余的遮挡掉不参与 loss 计算。再用伪标签进行监督，预测每一帧眨眼的置信度。



4.效果展示

4.1 多人条件下眨眼计数眨眼指标对比

在 MPEblink 拓展数据集下不同 clip_len 下指标对比

Clip_len	Ap25	Ap50	Ap75	Ap100	MAE	MSE
32	0	0	0	0	4.69	57.93
64	43.43	30.28	6.42	2.11	2.5	16.77
128	35.70	27.09	7.42	3.04	3.31	28.93
256	24.96	17.87	5.51	2.33	3.36	26.82
区间标签对照						
	41.89	34.83	16.64	14.13	2.79	24.66

其中 MAE 代表计数平均绝对损失，MSE 代表计数均方损失。区间标签指在所有模型结构完全相同，仅仅将模型中的伪标签换成真区间标签情况下训练的结果。

可见我们的模型训练时的 clip_len 不能太短，太短导致样本计数标签分布方差太小，标签之间的差异不足以使模型学习到眨眼的相关信息。而 clip_len 太长，眨眼稀疏程度大，训练将变得更加困难。

对比区间标签下训练的结果，我们的模型能够在 clip_len = 64 时实现计数性能的反超，并且能够大致检测动作区间，特别是在 iou=0.25 时，甚至超过了区间标签监督下的精度

总的来说，我们的算法极大降低了标注代价的同时，在拓展的多人眨眼检测数据集 MPEblink 上取得了超过区间标签监督下的计数性能，以及相近的检测性能。

4.2 视线估计在 MPEblink 上的可视化



我们使用 MCGaze 在拓展的多人 MPEblink 数据集上推理，实现了多人条

件下较为准确的视线估计。未来或许可以通过 MCGaze 生成的 gaze 伪标签，做多人下的视线估计，眨眼检测一体化。

5.主要工作和创新点

1) 拓展了原有的多人眨眼检测数据集 MPEblink, 补充了更加具有挑战性的 7 人以上多人样本。

2) 提出了一种两阶段训练多人眨眼计数算法，解决了短序列训练眨眼次数标签丰度不够导致模型难以学习到稀疏眨眼信息的问题。极大降低了标注代价的同时，在拓展的多人眨眼检测数据集 MPEblink 上取得了超过区间标签监督下的计数性能，以及相近的检测性能。

3) 同时复现了 MCGaze，一种一体检测视线估计化的视线估计算法，在 MPEblink 拓展数据集上推理，验证了其在多人复杂场景下的效果。

参考文献

^[1] Pan, G., Sun, L., Wu, Z. and Lao, S., 2007, October. Eyeblink-based anti-spoofing in face recognition from a generic webcam. In 2007 IEEE 11th international conference on computer vision (pp. 1-8). IEEE.

^[2] Drutarovsky, T. and Fogelton, A., 2015, March. Eye blink detection using variance of motion vectors. In Computer Vision-ECCV 2014 Workshops: Zurich, Switzerland, September 6-7 and 12, 2014, Proceedings, Part III (pp. 436-448). Cham: Springer international Publishing.

^[3]TalkingFaceVideo[EB/OL]-http://www.prima.inrialpes.fr/FGnet/data/01-TalkingFace/talking_face.html

^[4] Radlak, K., Bozek, M. and Smolka, B., 2015, November. Silesian deception database: Presentation and analysis. In Proceedings of the 2015 ACM on Workshop on Multimodal Deception Detection (pp. 29-35).

^[5] Daza, R., Morales, A., Fierrez, J. and Tolosana, R., 2020, October. MEBAL: A multimodal database for eye blink detection and attention

level estimation. In Companion Publication of the 2020 International Conference on Multimodal Interaction (pp. 32-36).

^[6] Hu, H., Dong, S., Zhao, Y., Lian, D., Li, Z. and Gao, S., 2022. TransRAC: Encoding Multi-scale Temporal Correlation with Transformers for Repetitive Action Counting. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (pp. 19013-19022).

^[7] Zeng, W., Xiao, Y., Wei, S., Gan, J., Zhang, X., Cao, Z., Fang, Z. and Zhou, J.T., 2023. Real-time Multi-person Eyeblink Detection in the Wild for Untrimmed Video. arXiv preprint arXiv:2303.16053

^[8] O. Levy and L. Wolf, "Live Repetition Counting," 2015 IEEE International Conference on Computer Vision (ICCV), Santiago, Chile, 2015

^[9] H. Hu, S. Dong, Y. Zhao, D. Lian, Z. Li and S. Gao, "TransRAC: Encoding Multi-scale Temporal Correlation with Transformers for Repetitive Action Counting," *2022 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, New Orleans, LA, USA, 2022, pp. 18991-19000,

^[10] PoseRAC: Pose Saliency Transformer for Repetitive Action Counting, Yao, Ziyu and Cheng, Xuxin and Zou, Yuexian, arXiv preprint arXiv:2303.08450, 2023

^[11] Lee, Pilhyeon et al. "Weakly-supervised Temporal Action Localization by Uncertainty Modeling." AAAI Conference on Artificial Intelligence (2020).

^[12] X. Zhang, Y. Sugano, M. Fritz, and A. Bulling, "Appearance-based gaze estimation in the wild," in The IEEE Conference on Computer Vision and Pattern Recognition (CVPR), June 2015.

^[13] Guan, Yiran and Chen, Zhuoguang and Zeng, Wenzheng and Cao, Zhiguo and Xiao, Yang, IEEE Signal Processing Letters, End-to-end Video Gaze Estimation via Capturing Head-face-eye Spatial-temporal Interaction Context